

# Wikipedia Madde Çekme ve S3'e Kaydetme Pipeline'ı

**Kapsam:** Wikipedia çekme → S3 (metin) + DB (kayıt)

**Format:** User Story + Acceptance Criteria

**Lisans:** CC BY-SA 4.0

## User Story

Bir içerik operatörü olarak, ilgi çeken bir Wikipedia konusunu (örn. **“Augustus”**) sisteme verdiğimde, maddenin metninin S3'te (ham ve seslendirmeye hazır temizlenmiş hali) saklanması; kaynak, lisans ve S3 işaretçileri dâhil tüm metadata'nın ise **DB'de tek bir kayıt altında bir id ile** tutulmasını istiyorum; böylece sonraki aşamalar metni S3'ten id üzerinden çözüp temiz bir girdiden başlar ve CC BY-SA atıf yükümlülüğü kayıt üzerinden pipeline boyunca kaybolmaz.

## Açıklama / Bağlam

n8n workflow'u Wikipedia API üzerinden madde içeriğini çeker, iki aşamalı işler ve sonuçları iki katmana yazar. **S3 (object store)** yalnızca metnin kendisini tutar: ham içerik raw/ altına, temizlenmiş düz metin formatted/ altına. **DB ise** her madde için tek bir kayıt tutar; bu kayıt bir id, kaynak/lisans metadata'sı ve S3 nesnelere işaretçileri (anahtar/URI) içerir. Yani metin S3'te, **diğer her şey DB'de id ile** yaşar.

Wikipedia içeriği **CC BY-SA 4.0** lisanslıdır; bu, türetilen her çıktının (a) kaynağa atıf vermesini, (b) yapılan değişikliğin belirtilmesini, (c) türev metnin aynı lisansla paylaşılmasını (ShareAlike) gerektirir. Bu yükümlülüğün sonradan eklenmesi zordur; bu yüzden lisans/atıf metadata'sı **ilk çekme anında DB kaydına** yazılır ve S3'teki her nesneyle ilişkilendirilir.

## Lisans & Atıf Gereksinimi — Birinci Sınıf

Her madde için **DB kaydı**, taşınabilir bir atıf bloğu ve S3 işaretçilerini içerir. Asgari alanlar:

|                          |                                                              |
|--------------------------|--------------------------------------------------------------|
| id                       | kaydın benzersiz kimliği (sonraki aşamalar bununla çözer)    |
| source_url               | maddenin tam Wikipedia URL'i                                 |
| article_title / language | madde başlığı ve dil                                         |
| revision_id              | atfın belirli bir sürüme bağlanması için                     |
| license                  | CC BY-SA 4.0                                                 |
| license_url              | lisans metnine bağlantı                                      |
| retrieved_at             | çekme zaman damgası                                          |
| modified                 | içeriğin değiştirilip değiştirilmediği (formatted için true) |
| s3_raw_key               | ham metnin S3 anahtarı/URI'si                                |
| s3_formatted_key         | temizlenmiş metnin S3 anahtarı/URI'si                        |

Atıf bloğu **DB kaydında** yaşar; S3'teki raw ve formatted nesneleri bu kayda id ve anahtarlar üzerinden bağlıdır. Böylece sonraki aşamalar (enrichment, audio) atfı **kayıptan** koruyarak ileri taşır.

## Acceptance Criteria

- 1. Girdi:** Workflow bir konu başlığı (ve opsiyonel dil kodu, varsayılan en) ile tetiklenebilir.
- 2. Çekme:** Wikipedia API'den madde içeriği çekilir. Bulunamayan veya disambiguation maddeleri hata değil anlamlı durumla (not\_found / disambiguation) sonlanır ve loglanır.
- 3. DB kaydı oluşturma:** Çekme başarılıysa madde için bir id ile DB kaydı açılır; kaynak/lisans metadata'sı (source\_url, revision\_id, license vb.) bu kayda **ilk çekme anında** yazılır. revision\_id mutlaka API yanıtından alınır.
- 4. Raw metin → S3:** Ham içerik değiştirilmeden S3'e raw/ altına yazılır; nesnenin anahtarı/URI'si DB kaydındaki s3\_raw\_key alanına işlenir.
- 5. Temizlik (formatted):** Ham içerikten seslendirmeye düşman öğeler ayıklanır: dipnot/referans işaretleri, tablolar/infobox, parantez içi telaffuz ve fonetik gösterimler, wiki markup artıkları, tarih/kısaltma normalizasyonu.
- 6. Formatted metin → S3 + kayıt:** Temizlenmiş metin S3'e formatted/ altına yazılır; anahtarı s3\_formatted\_key alanına işlenir ve DB kaydında modified: true olarak işaretlenir.
- 7. İlişki bütünlüğü:** DB kaydı ile S3 nesneleri id ve anahtarlar üzerinden tutarlı biçimde bağlıdır; kayıttaki s3\_\*\_key değerleri gerçek, erişilebilir nesnelere işaret eder (sarkan/kırık işaretçi bırakılmaz).
- 8. Adlandırma & idempotency:** S3 anahtarları deterministik bir şemayla üretilir (ör. {lang}/{slug}/{revision\_id}); aynı madde-revizyonu tekrar çekildiğinde ne mükerrer DB kaydı ne de mükerrer/çelişen S3 nesnesi oluşur (upsert davranışı).
- 9. Atıf taşınabilirliği:** DB kayıt şeması, sonraki aşamaların (enrichment, audio) ek geliştirme yapmadan id ile çözüp atfı okuyabileceği biçimde nettir ve dokümente edilir.
- 10. Hata yönetimi:** API/boş içerik/S3 yazma/DB yazma hatasında başarısız adım loglanır; kısmi durum bırakılmaz (ör. S3'e yazılıp DB'ye işlenmemiş veya tersi nesne kalmaz).

- 11Doğrulama — içerik:** Augustus ile uçtan uca çalıştırıldığında S3'te raw ve formatted nesneleri oluşur ve formatted metninde tablo/dipnot/markup artığı bulunmaz.
- 12Doğrulama — kayıt & lisans:** Aynı çalıştırmada oluşan DB kaydının eksiksiz olduğu doğrulanır: tüm asgari atıf alanları dolu, revision\_id gerçek bir sürüme işaret ediyor, s3\_raw\_key ve s3\_formatted\_key erişilebilir nesnelere çözülüyor. Eksik/boş lisans alanı veya kırık işaretçi olan kayıt kabul edilmez.

## Kapsam Dışı (Out of Scope)

- **LLM enrichment** (ayrı PBI) — ancak atıf bloğunu taşımak ve modified: true korumakla yükümlüdür.
- **ElevenLabs seslendirme** (ayrı PBI) — audio metadata'sında / uygulama içi “Kaynaklar” görünümünde atfın yüzeye çıkması ayrı PBI'da ele alınır.
- **Atfın son kullanıcıya gösterimi** (UI'da kaynak/lisans listesi) — ayrı PBI.

## Bağımlılıklar / Notlar

- S3, DB ve n8n ortamı hazır olmalı; Wikipedia API rate limit'lerine uyulmalı.
- **Sorumluluk ayrımı:** Metnin kendisi S3'te; id, atıf/lisans ve S3 işaretçileri dâhil diğer her şey DB'de tutulur.
- **Atıf zinciri prensibi:** Lisans bilgisi DB kaydında yaşar ve pipeline'ın hiçbir aşamasında düşürülmemelidir; her aşama kaydı id ile çözer, korur, ileri verir.
- Bu PBI yalnızca metni S3'e yazmak ve DB kaydını **üretim ilişkilendirmekten** sorumludur; kullanıcıya **sunum** kapsam dışıdır ama bu PBI olmadan yapılamaz.

---

Wikipedia içeriği CC BY-SA 4.0 lisansı ile kullanılmaktadır. Türev çıktılar atıf ve aynı lisansla paylaşım (ShareAlike) şartlarına tâbidir.